CLIP

Learning Transferable Visual Models From Natural Language Supervision

박철우

Introduction and Motivating work

- NLP의 변화

1. Raw Text -> pre-training
2. Task-agnostic Objectives + scaling
3. Text-to-Text interface -> zero-shot transfer
4. GPT-3

-> **GPT-3는 웹 규모 텍스트로 사전 학습된 대표적인 모델로, 대규모 사전 학습의 효과와 제로샷 전이 능력을 보여주었다.**

Introduction and Motivating work

- CLIP 이전의 발전 과정

1. Predict nouns and adjectives (1999)
2. Image metadata -> Bag-of-words multi-label classification (2016)
3. Phrase n-gram prediction for zero-shot transfer (2017)
4. Transformer, MLM, Contrastive Learning (2020)

   -VirTex, ICMLM, ConVIRT

But, 자연어 감독을 사용하는것은 여전히 힘듦

Introduction and Motivating work

- Weak supervision 방식

  - gold-label의 고품질과 raw text의 대규모 양 사이의 실용적 중간지점

- Weak supervision

1) Instagram에서 ImageNet 관련 해시태그를 예측하도록 사전 학습
   - ImageNet fine-tuning후 정확도 약 5% 향상

2) JFT-300M 데이터셋의 클래스를 예측하도록 사전 학습
   - 많은 전이 벤치마크 세트에서 큰 성능 향상을 입증

Introduction and Motivating work

- Weak supervision의 한계

1. Class 범위를 1000개, 18291개로 제한
2. Static softmax classifiers 사용
3. Zero-shot 능력 제한

Introduction and Motivating work

- 규모로 인한 차이

1. Weak supervision
   - 수백만~ 수십억 개의 이미지에 대해 가속기 연산 기준 수년간 모델 학습

2. VirTex, ICMLM, ConVIRT
   - 10만~20만개 이미지에 대해 가속기 연산 기준 수일 동안 학습

- CLIP

1. 4억 개의 이미지-텍스트 쌍
2. 크기가 다른 CLIP 모델 8개를 학습
   - Scaling 경향 발견
3. 사전 학습중 여러 작업 능력 학습
   - OCR, 위치 추정, 행동 인식
4. Zero-shot transfer 성능
   - 30개 이상의 기존 작업별 지도 학습 모델들과 경쟁 가능
   - 견고성
5. Linear-probe에서 성능 우수

Approach

- Natural Language Supervison으로 이름 통합

1. 예전에는 unsupervised, self-supervised, weakly supervised, supervised respectively 등으로 불림
   - 공통점 : 모두 자연어를 학습신호로 사용 -> 자연어 감독

- Natural Language Supervison 장점

1. 인터넷의 대규모 이미지-텍스트 데이터 활용
2. 자연어와 연결된 이미지 표현 학습

Creating a Sufficiently Large Dataset

- 기존 데이터셋의 한계

1. MS-COCO / Visual Genome : 고품질, 소규모
2. YFCC100M : 대규모, 품질 불균일
   - 1억장의 이미지 -> 1500만장의 이미지

- 새로운 CLIP 데이터셋 (WIT)

1. 4억 개의 이미지-텍스트 쌍
2. 50만개의 검색 쿼리
3. 쿼리당 최대 2만 쌍 포함
   - 특정 개념에 데이터 몰림 방지

Selecting an Efficient Pre-Training Method

- 기존 비전 모델들은 ImageNet의 1000개 클래스를 학습하는데 오래걸림
  - Ex) 19 GPU-year, 33 TPUv3 core-year

-> 따라서, 자연어 감독을 위한 효율적인 학습 방법 필요

Selecting an Efficient Pre-Training Method

1. Transformer Language Model

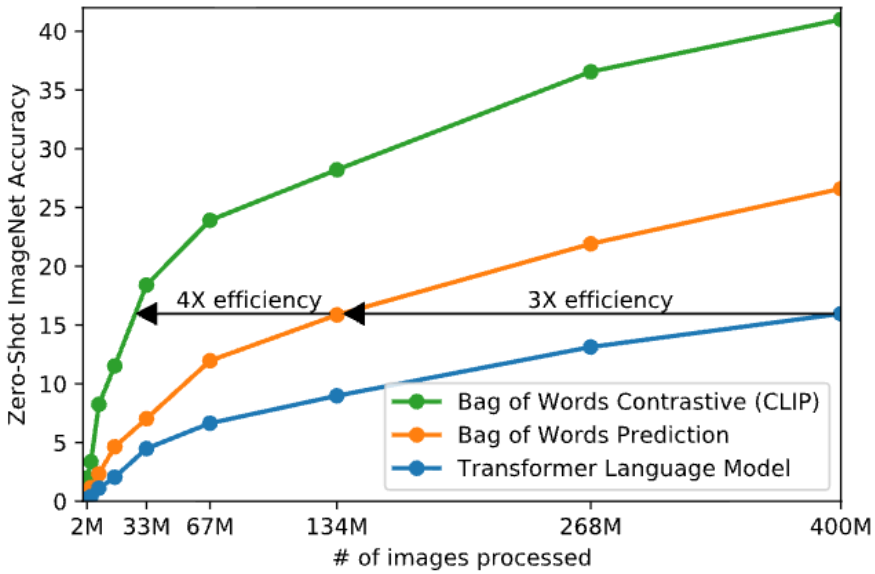
1. 캡션 생성
2. Bag-of-Words 예측보다 학습 속도 3배 느림

2. Bag-of-Words Prediction

1. 캡션에 포함된 단어들을 예측

3. Bag-of-Words Contrastive

1. 정확한 단어 예측하지 않고 대조
2. Bag-of-Words 예측 방식보다 약 4배 효율적



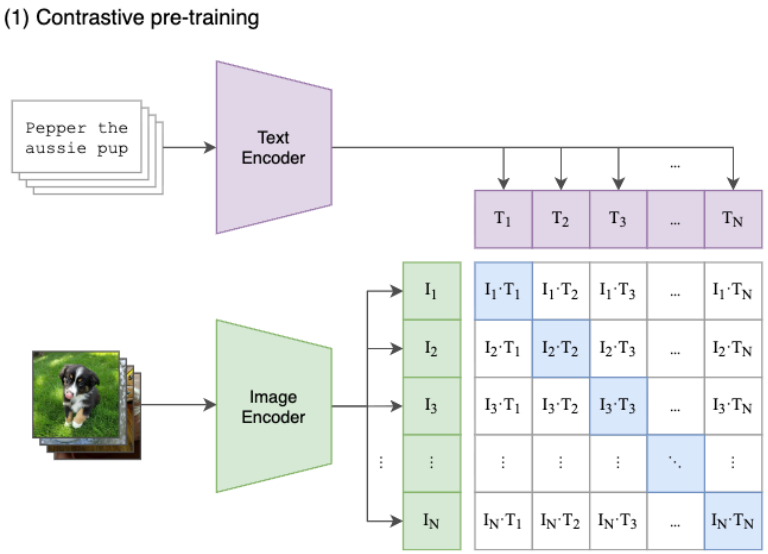
Selecting an Efficient Pre-Training Method

1. Batch
   - N개의 이미지-텍스트 쌍
   - N x N

2. Encoder
   - Image : $I_1, ..., I_N$
   - Text : $T_1, ..., T_N$

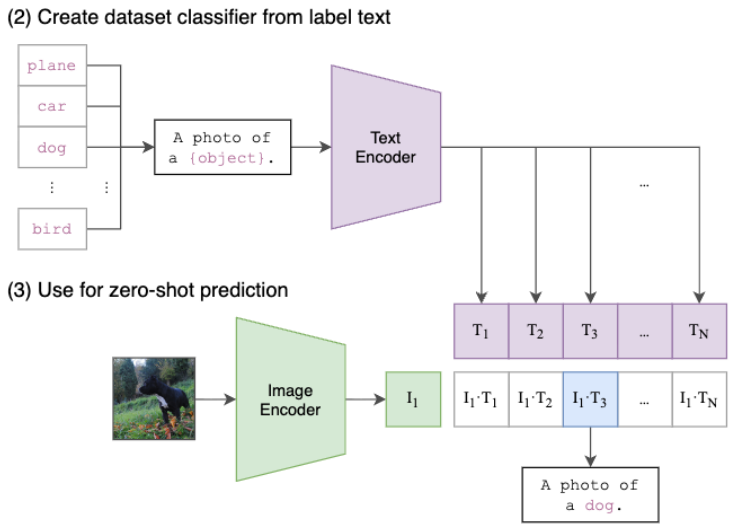
3. 대칭적 교차 엔트로피 손실
   - 이미지 -> 텍스트
   - 텍스트 -> 이미지

4. 코사인 유사도
   - 이미지 벡터와 텍스트 벡터의 방향

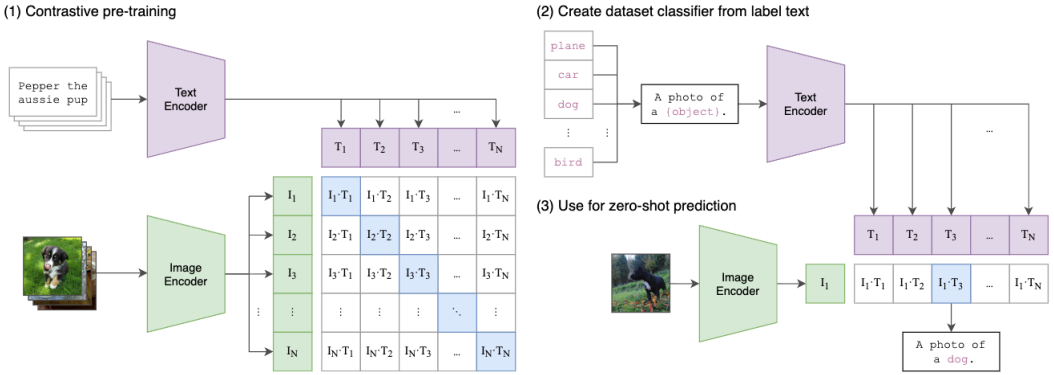


Selecting an Efficient Pre-Training Method

1. 학습이 끝난 CLIP을 이용한 제로샷 분류 과정



Selecting an Efficient Pre-Training Method



ConVIRT 보다 단순한 CLIP

1. 선형투영
   - 이미지, 텍스트 공통 embedding 공간

2. 데이터 증강도 단순화
   - Random square crop 사용

3. 온도 파라미터 T
   - `logits = np.dot(I_e, T_e.T) * np.exp(t)`

Choosing and Scaling a Model

Emage Encoder

1. ResNet-50
   - ResNetD
   - Blur Pooling 사용
   - Global average Pooling -> Attention Pooling

2. VIT
   1. Layer Normalization 추가
   2. 약간 다른 초기화 방식 사용

Choosing and Scaling a Model

Text Encoder (Transformer)

1. Transformer 구성
   - 12-layer
   - Width: 512
   - 8 attention heads
   - 약 63M parameters

2. Text Embedding 과정
   1. BPE 토큰화
   2. [SOS], [EOS] 추가
   3. Transformer 인코딩 -> [EOS] 특징 추출
   4. LayerNormalization + Linear Projection
   5. Text Embedding 생성

Choosing and Scaling a Model

Scale

1. Image Encoder
   - 기존 연구
     - 모델의 깊이만 증가 또는 너비만 증가
   - CLIP
     - 추가 연산량을 너비, 깊이, 해상도에 균형있게 분배
2. Text Encoder
   - 너비만 증가
   - 깊이 고정

Training

Model

- ResNet
  - RN50, RN101
  - RN50x4, RN50x16, RN50x64
- Vision Transformer
  - Vit-B/32
  - Vit-B/16
  - Vit-L/14
- 학습 방법
  - Adam Optimizer
  - Cosin LR scheduler
  - 32 Epoch
- Largest Model
  - RN50x64 : 592 V100 GPUs (18days)
- Best Model
  - Vit-L/14@336px