CPL-VAD

2026.08.20. 목요일

전북대학교 PARS 연구실





Introduction

CPL-VAD

Video-level label만 사용하여 Binary Anomaly Detection과 Abnormal Category Classification을 동시에 수행하는 WSVAD 기반 Dual-Branch Framework이며

B-branch와 C-branch가 Cross Pseudo Labeling을 통해 각 branch의 강점을 상호보완하는 방식

- B-branch : Binary Anomaly Detection
- C-branch : Abnormal category Classification

Introduction

B-branch vs C-branch

	B-branch	C-branch
역할	Binary Anomaly Detection	Abnormal Category Classification
특징	Video feature 기반	Video-text alignment 기반
장점	Motion, Appearance의 temporal change에 민감 -> 정확한 anomaly localization	Clip의 풍부한 semantic knowledge활용 -> 다양한 abnormal category 구분
단점	미묘하거나 semantic하게 복잡한 anomaly를 놓칠 수 있음 -> False Negative	Temporal boundary를 명시적으로 modeling하지 않아 anomaly region을 과대평가할 수 있음 -> False Positive

Introduction

Cross Pseudo Labeling (CPL)

- video-level supervision으로 학습된 각 branch의 prediction을 기반으로 sinppet-level pseudo label 생성
- 생성된 pseudo label을 상대 branch의 supervision으로 활용
- 서로 다른 강점을 교환하여 각 branch의 한계를 상호보완

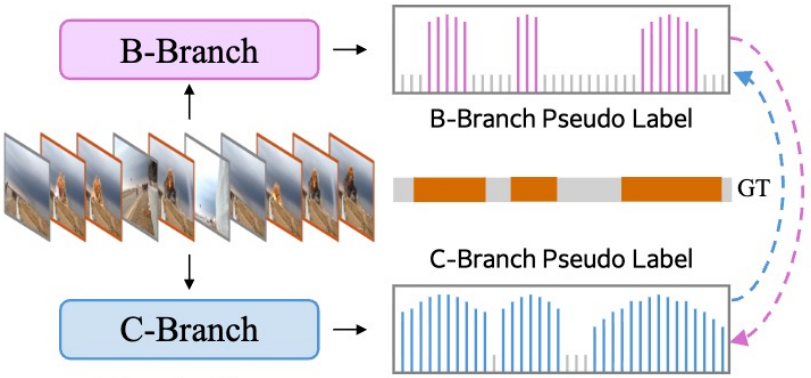


Fig. 1. Cross pseudo labeling framework.

Introduction

문제점

그런데 각 branch의 Raw prediction을 그대로 pseudo label로 사용해도 될까?

-> Raw prediction에는 temporal inconsistency, scale inconsistency, outlier가 포함될 수 있음

해결

CAR (Consistency-Aware Refinement) 제안

-> 일관되고 신뢰도 높은 pseudo label 생성

Architecture

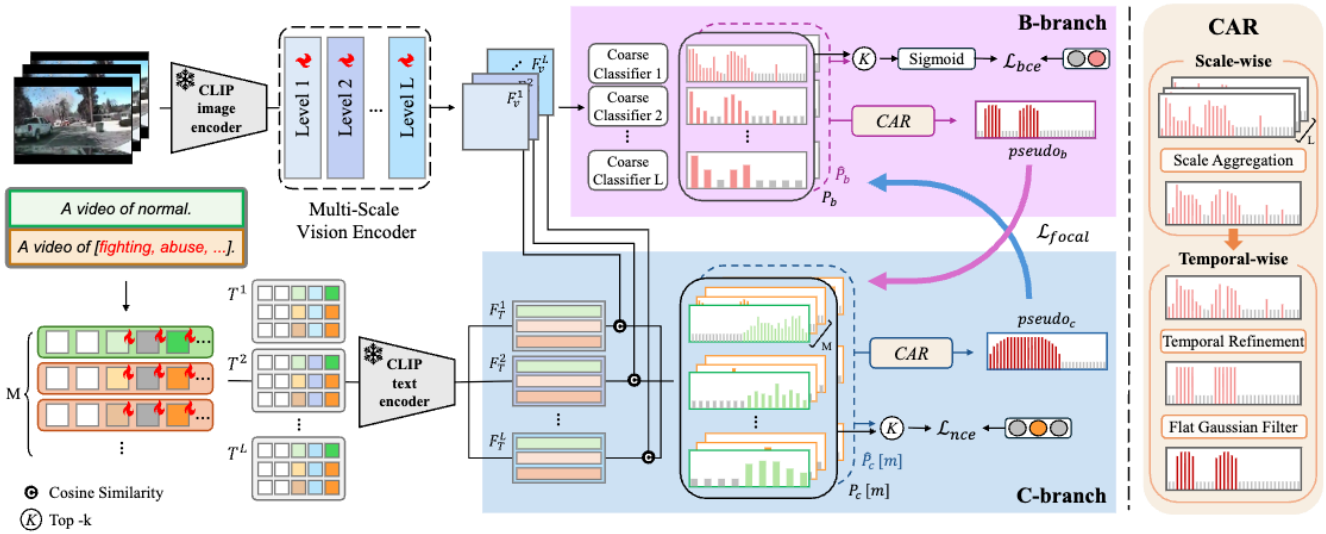


Fig. 2. The framework of CPL-VAD and Consistency-Aware Refinement module.

Method

CPL-VAD는 Pseudo Label Generation stage 과 Final prediction stage 총 2단계 설계로 이루어져 있다.

1. Pseudo Label Generation stage

B-branch prediction($\hat{P}_b$) → car → Pseudo_b

C-branch prediction($\hat{P}_c[m]$) → car → Pseudo_c

2. Final prediction stage

Pseudo_c → B-branch → 최종 Binary anomaly detection P_b

Pseudo_b → C-branch → 최종 category classification $P_c[m]$

Method

Feature Extraction

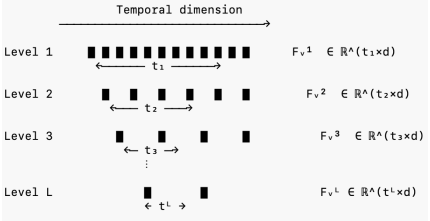
frozen CLIP image encoder를 사용하여 snippet-level 피처 $X_{\text{clip}} \in \mathbb{R}^{n \times d}$ 를 추출

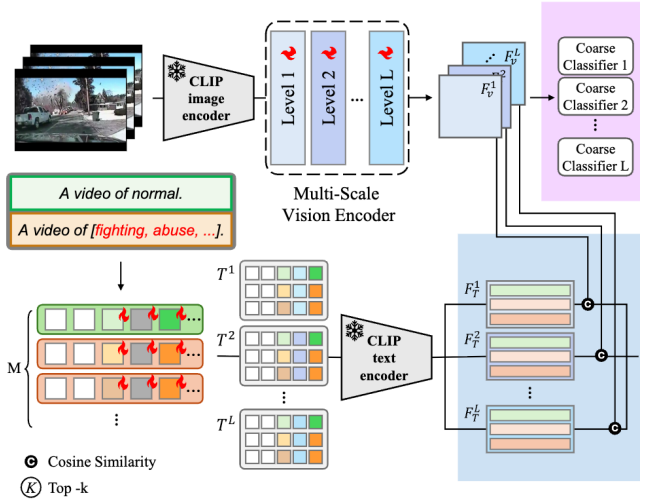
- n : snippet 수
- d : feature 차원

이 feature들은 ActionFormer 기반의 시간 인코더(temporal encoder)를 거쳐 multi-temporal scale의 video feature $\{F_v^i\}_{i=1}^{L}$ 를 얻는다.

$F_v^i \in \mathbb{R}^{t_i \times d}$ 는 level i에서의 temporal context를 담고 있다.

- L : 전체 level 수
- t_i : 해당 scale에서의 temporal length



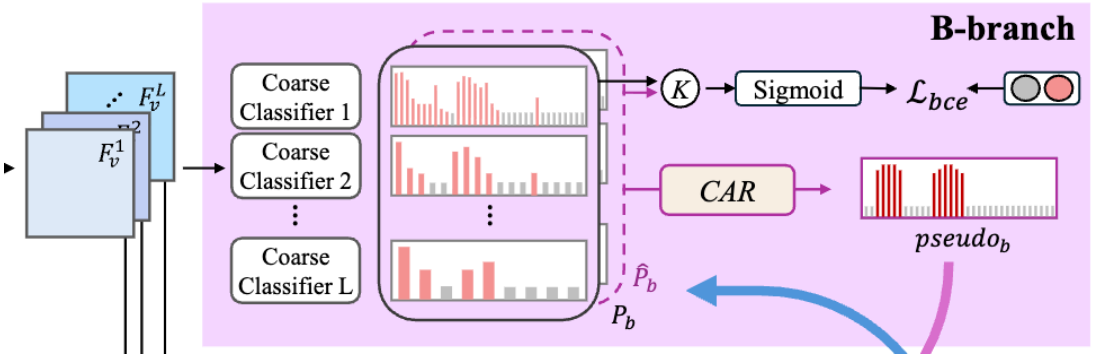


Method

B-branch

각 $\{F_v^i\}_{i=1}^L$에 MLP classifier를 적용하여 각 level의 video feature에 대한 multi-scale anomaly score $\hat{P}_b = \{\hat{p}_b^i\}_{i=1}^L$ and $P_b = \{p_b^i\}_{i=1}^L$ 를 예측한다.

$\hat{P}_b$: Pseudo label 생성
P_b : Final prediction score



Method

C-branch

CLIP text encoder와 multi-level prompt learning을 통해 Abnormal category classification 수행

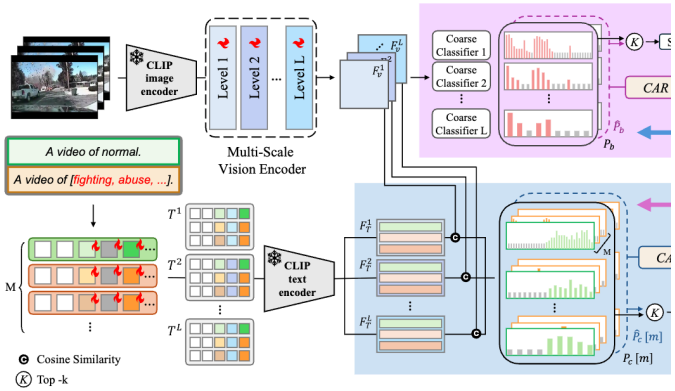
A video of [class] 같은 text prompt들을 각 temporal scale에 맞게 T^i 로 변환

$$T^i = [\mathtt{A}]\,[\mathtt{video}]\,[\mathtt{of}]\,[\mathtt{class}]\,[N_P, A_P]\,[Q_P^i]$$

$[N_P, A_P]$: 모든 class와 모든 level에서 공유됨, normal/abnormal 관련 token
$[Q_P^i]$: level i에서만 공유되는 level 전용 token

Prompt들은 CLIP text encoder 통과하여 text feature $F_T^i \in \mathbb{R}^{M \times d}$ 생성

M : categary의 수



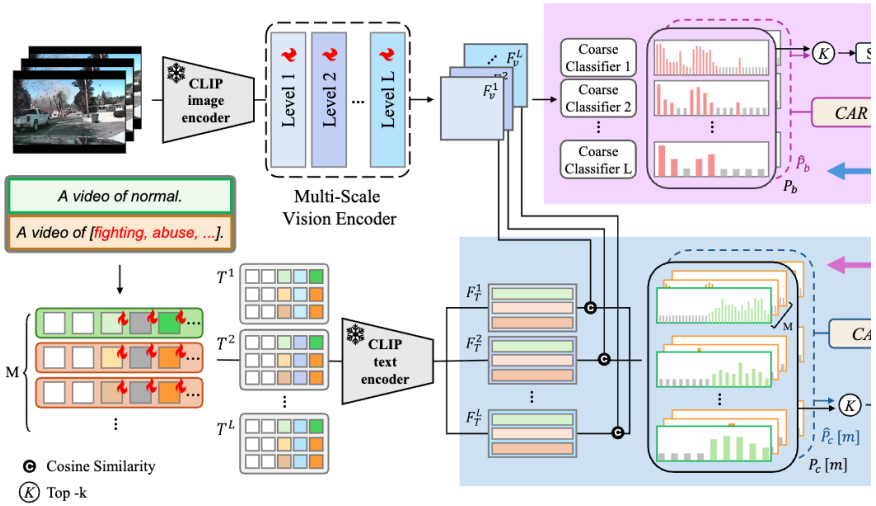
Method

F_T^i and F_v^i 사이의 similarity score를 계산하여
multi-class anomaly category score인 $\hat{P}_c[m] = \{\hat{p}_c^i[m]\}_{i=1}^L$ 와 $P_c[m] = \{p_c^i[m]\}_{i=1}^L$ 를 얻음

similarity

Video F_v^i Normal F_T^i ➡ 0.1
Video F_v^i Fighting F_T^i ➡ 0.8
Video F_v^i Shooting F_T^i ➡ 0.2

Similarity scores at t = [0.1, 0.8, 0.2]



Method

Cross Pseudo Labeling (CPL)

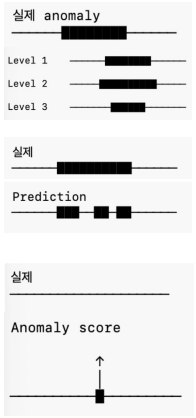
B-branch와 C-branch 사이를 Pseudo label 이용하여 상호보완하는 방법

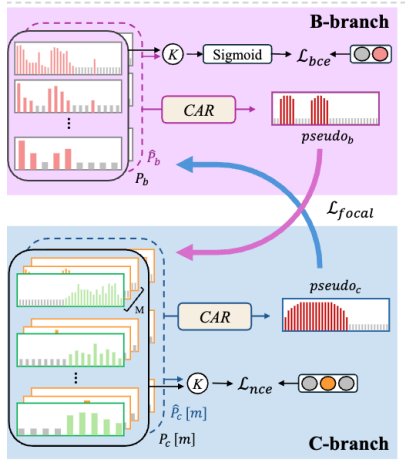
각 branch의 raw prediction을 직접 pseudo label로 사용할 경우 불안정이 발생할 수 있음

불안정 문제 3가지

1. Inconsistent boundaries across temporal scales
   - level마다 boundary가 안 맞는 문제
2. Fragmented intervals
   - 하나의 anomaly 구간을 여러 조각으로 예측하는 문제
3. Short spurious spikes
   - 짧게 튀어나오는 False Alarm 문제

⇨ CAR 이용





Method

Cross Pseudo Label Logits

1. Video-level GT로 $\hat{P}_b$, $\hat{P}_c[m]$ 학습

2. 각 branch의 logit을 비교 가능한 형태로 전처리

- Normalization + temporal upsampling
  -> 동일한 sequence length로 정렬
- C-branch: 모든 abnormal class score를 softmax 적용 후 합쳐 하나의 abnormality logit 생성

3. 각각 CAR에 입력하여 pseudo lable 생성

$$\hat{P}_b \rightarrow CAR \rightarrow pseudo_b \qquad pseudo_b \rightarrow C-\text{branch}$$

$$\hat{P}_c[m] \rightarrow CAR \rightarrow pseudo_c \qquad pseudo_c \rightarrow B-\text{branch}$$



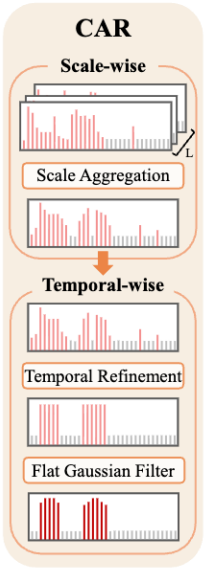
Method

Consistency-Aware Refinement (CAR)

Raw multi-scale logit을 두 단계에 걸쳐 정제하여 신뢰도 높은 pseudo label을 생성하는 방법

1. Scale-wise Aggregation
   - scale간 prediction inconsistency 해결

2. Temporal Refinement
   - 시간축의 prediction inconsistency 해결



Method

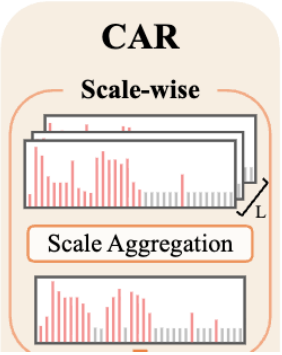
Scale-wise Aggregation

서로 다른 temporal scale의 prediction을 일관성에 따라 통합하여 reliable한 aggregated logit 생성

1. Scale 간 similarity 계산
   - Adaptive Gaussian RBF Kernel 이용하여 동일한 video 시점 t에서 scale 간 prediction score의 유사도 계산

2. Scale 별 weight 결정
   - 다른 scale들과 유사할수록 높은 weight, 동떨어질수록 낮은 weight

3. Weighted Aggregation
   - scale별 prediction을 weight에 따라 결합하여 하나의 aggregated logit 생성



⇨ Inconsistent boundaries across temporal scales 문제 해결

Method

Adaptive Gaussian RBF Kernel

Scale간 prediction score가 얼마나 유사한지 측정하여 scale의 신뢰도를 결정
- Bandwidth는 MAD를 이용해 상황에 맞게 adaptive

$$w_t(i) = \frac{\sum_{j=0}^{L} e^{-\frac{(x_i - x_j)^2}{2\sigma^2}}}{\sum_{i=0}^{L}\sum_{j=0}^{L} e^{-\frac{(x_i - x_j)^2}{2\sigma^2}}}, \; i \neq j$$

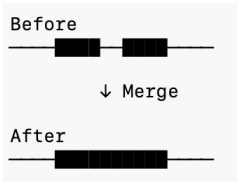
x_i , x_j : 동일한 snippet t에서 scale i, j가 예측한 score
x_i - x_j : 두 temporal scale의 prediction 차이
σ : MAD(Median Absolut Deviation)를 이용해 adaptive 하게 결정

Method

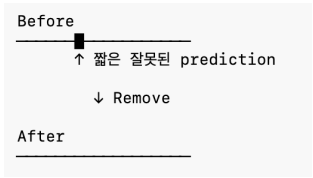
Temporal Refinement

Aggregated logit에 남아 있는 temporal inconsistency를 정제하여 연속적이고 안정적인 pseudo label 생성

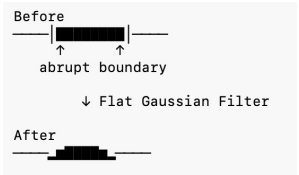
1. Abnormal Segment Grouping
   - 가까이 위치한 abnormal segment들을 하나의 연속된 구간으로 merge
   -> Fragmented intervals 완화

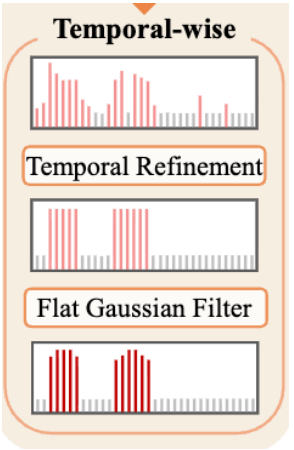


2. Short Segment Filtering
   - 고립된 짧은 abnormal segment 제거
   -> Short spurious spikes 완화



3. Flat Gaussian Filtering
   - Abnormal region의 boundary를 부드럽게 조정
   - 중심부는 강한 supervision, 불확실한 boundary는 약한 supervision





Method

Cross-Branch optimization

생성된 pseudo label을 실제 학습에 어떻게 사용하는지를 설명
Video-level supervision과 상대 branch가 생성한 pseudo label을 이용한 snippet-level supervision 사용

1. Video-level supervision

   B-branch

   $\hat{P}_b$, P_b 에서 confidence가 높은 Top-K snippet 선택
   Video-level GT와 Binary Cross-Entropy Loss $\mathcal{L}_{bce}$ 계산

   C-branch

   $\hat{P}_c[m]$, $P_c[m]$ 에서 각 class별 confidence가 높은 Top-K snippet 선택
   Video-level GT와 Cross-Entropy Loss $\mathcal{L}_{nce}$ 계산

Method

Cross-Branch optimization

2. Focal Loss $\mathcal{L}_{focal}$
   - Abnormal snippet이 Normal snippet보다 적어 발생하는 Class Imbalance 문제 완화
   - 상대 branch의 pseudo label과 final prediction 간 Focal loss 계산

   C-Branch는 multi-class prediction을 사용하므로 $1 - P_c[0]$ 을 이용하여 Abnormal Confidence 구함
   - B-branch의 pseudo label이 normal/abnormal 정보

$$\mathcal{L}_{total} = \mathcal{L}_{bce} + \mathcal{L}_{nce} + \mathcal{L}_{focal}.$$