VadCLIP

Adapting Vision-Language Models for Weakly Supervised Video Anomaly Detection

박철우

Introduction

Weakly Supervised VAD (WSVAD)

- 의미

-학습 시 영상 전체에 대해 frame-level annotation 없이 video-level label(normal/abnormal)만 제공

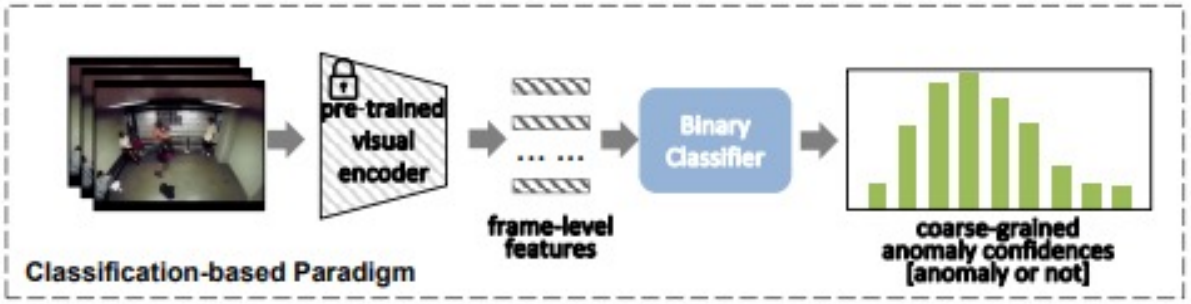
- 학습 목표

- Video-level label만 이용해서, 영상 내 각 frame 또는 segment의 anomaly confidence를 예측

Introduction

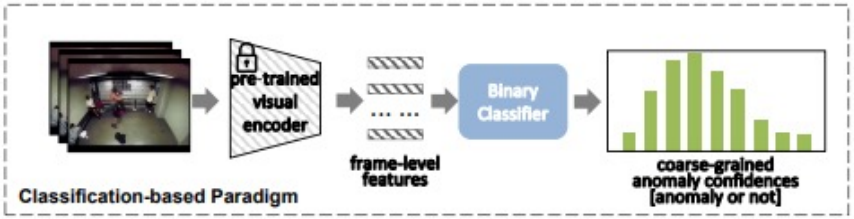
기존 WSVAD 연구

1. C3D, I3D, ViT 등의 사전 학습된 visual model을 통해 frame-level feature 추출
2. 추출한 feature들을 MIL 기반 Binary Classifier에 입력하여 모델 학습
3. 예측된 anomaly confidence에 기반하여 abnormal event 탐지



Introduction

기존 WSVAD 연구 한계



1. Visual feature에만 의존
   -> Vision-Language의 semantic association 활용하지 못함

2. Binary Clasification 기반
   -> Normal/ Abnormal만 구분 가능
   -> Anomaly category 분류 어려움

Introduction

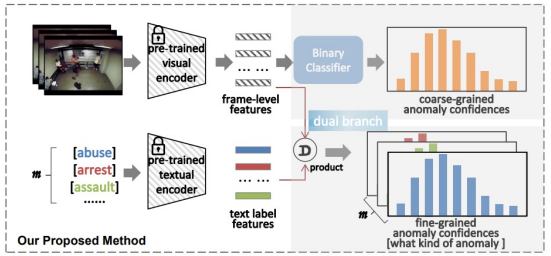
CLIP

1. 대규모 image-text pair로 사전학습
2. Contrastive learning을 통해 image와 text를 같은 embedding space에 정렬
3. 풍부한 semantic information을 포함한 강력한 visual representation 학습
4. Vision과 Language의 semantic association 활용 가능

-> 기존 WSVAD는 visual feature만 사용하였다. 그렇다면 CLIP의 Vision-Language semantic association을 활용할 수 있지 않을까?

Introduction

CLIP을 WSVAD에 적용하기 위한3가지 Challenge



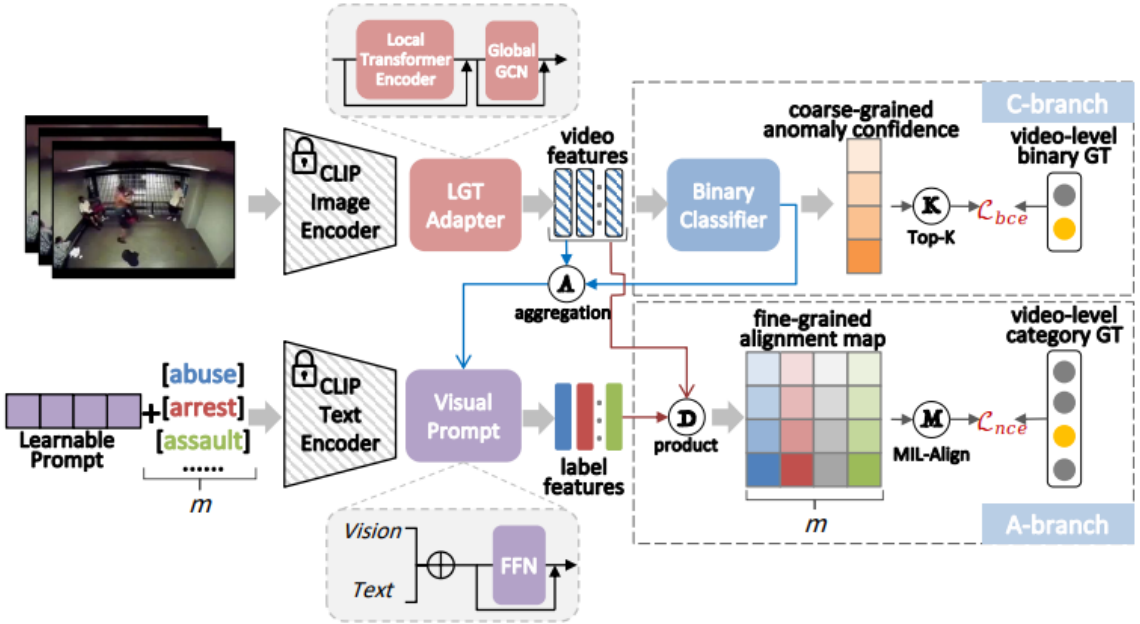
1. Temporal dependency를 어떻게 학습 할 것인가
   - LGT-Adapter

2. CLIP이 학습한 vision-language knowledge를 어떻게 활용할 것인가
   - Dual Branch + Prompt Mechanisms

3. Weak supervision 환경에서 Vision-Language alignment를 어떻게 학습하면서 CLIP의 knowledge를 보존할 것인가

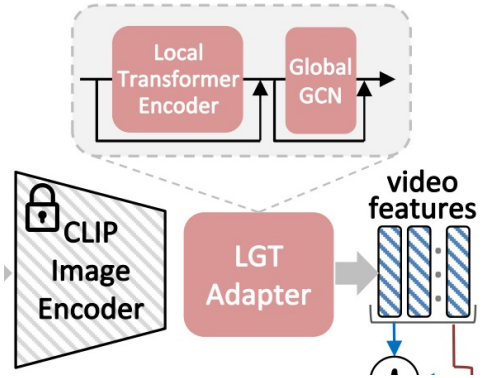
   - Frozen CLIP + MIL-Align

VadCLIP Architecture



Method

LGT-Adapter



목적

- CLIP을 image 기반 모델에서 video 기반 WSVAD로 확장
- 영상의 temporal dependency 학습

필요성

- 기존 CLIP은 시간 정보를 modeling 하지 못함
- WSVAD에는 short-range와 long-range temporal dependency 모두 고려해야 함

방법

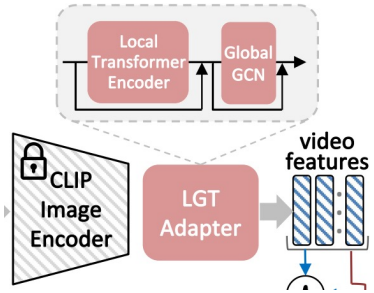
- Local Temporal Adapter와 Global Temporal Adapter 설계
- 연산 효율성과 receptive field 모두 고려
- Local-Global temporal information 모두 반영

Method

Local Module

- Local Temporal Dependency를 학습하기 위해 CLIP의 Image Encoder에서 추출한 frame-level feature인 X_{clip} 위에 Transformer Encoder Layer를 추가

$$X_{clip} \in \mathbb{R}^{n \times d}$$



X_{clip} : CLIP Image Encoder가 영상의 각 frame에서 추출한 feature들의 집합

n : video frame 수

d : 각 feature vector의 차원수 (512로 설정)

방법

- Frame-level Feature를 시간 축을 따라 동일 길이로 짤라 Overlapping Window로 분할
- 각 Window 내부에서 Self-Attention 수행하여 Local Temporal Dependancy 학습
- Window간 정보 교환 없음

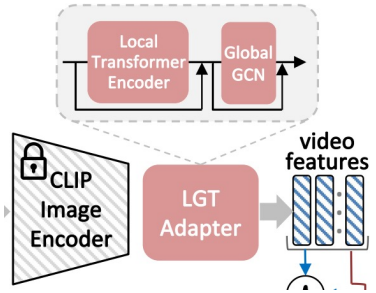
Local receptive field를 형성하며 일반 transformer보다 계산 복잡도를 줄일 수 있다는 장점이 있다.

Method

Global Module

- Global Temporal Dependency 학습하기 위해 GCN(Graph Convolutional Network) 모듈을 Local 모듈 뒤에 추가
  GCN을 VAD에 활용하기 위해 feature similarity와 position distance 함께 고려

$$X_g = gelu\left(\left[Softmax\left(H_{sim}\right); Softmax\left(H_{dis}\right)\right] X_l W\right)$$



H_{sim} : Frame 간 feature의 cosine similarity를 이용하여 만든 인접 행렬

H_{dis} : Frame 간 temporal distance를 이용하여 만든 인접 행렬

$Softmax$: 행렬의 값을 정규화하여 각 행의 합이 1이 되도록 만듦

X_l : Local module에서 얻은 frame feature

W : 학습 가능한 Weight Matrix

Method

Feature Similarity Branch

- Frame간 유사도 관계를 나타내는 인접 행렬 구할 수 있음

$$H_{sim} = \frac{X_l X_l^\top}{\|X_l\|_2 \cdot \|X_l\|_2}$$

- Local Module에서 나온 frame feature들끼리 cosine similarity 계산
- Feature가 비슷할수록 높은 연결 강도
- Threshold를 설정하여 약한 유사도는 0으로 수렴

Method

Position Distance Branch

- Frame간 상대적 시간 위치를 이용하여, Temporal Distance 인접 행렬을 구할 수 있음

$$H_{dis}(i,j) = \frac{-|i-j|}{\sigma}$$

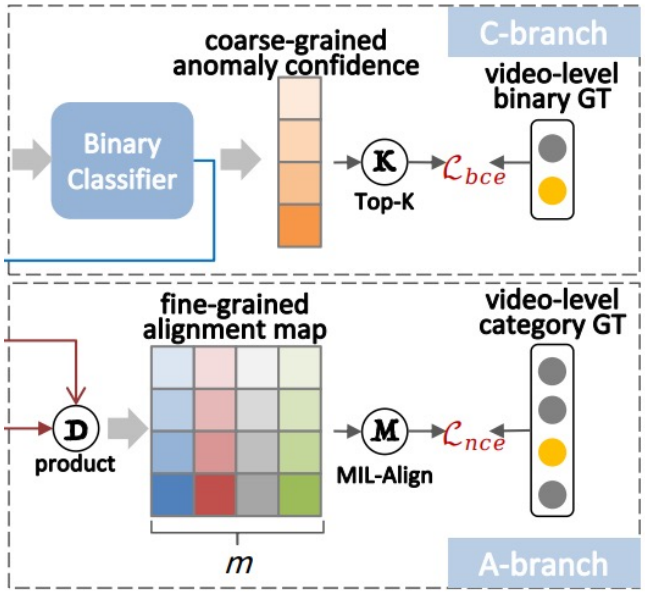
- 가까운 frame일수록 높은 relation

(i,j) : frame index
$-|i-j|$: 두 frame 사이의 상대적 시간 거리
σ : temporal distance의 영향 범위 조절하는 hyperparameter

Method

Dual Branch and Prompt

- 기존 WSVAD 연구들에서는 보통 binary classfier를 사용하는 C-Branch(coarse-Grained Branch)만 존재하는 반면, VADCLIP은 video-text alignment를 이용하는 A-Branch(fine-grained alignment branch)도 같이 사용한다

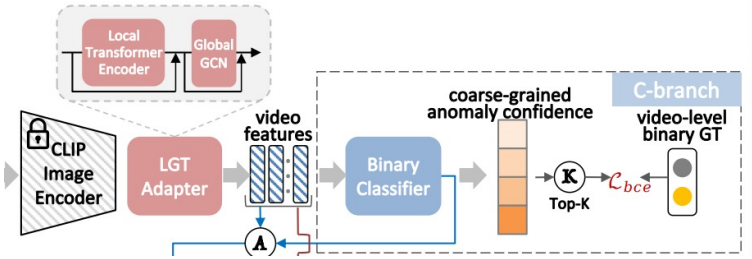


Method

C-Branch(Coarse-Grained Branch)

- LGT-Adapter에서 video feature를 입력 받아, 각 frame/segment의 anomaly confidence를 예측하고 video-level Normal/Abnormal을 구분하는 방법

$$A = Sigmoid\left(FC\left(FFN\left(X\right) + X\right)\right)$$



X : LGT-Adapter에서 얻은 video feature
A : frame/segment-level anomaly confidence score
FFN : 입력 feature를 여러 Linear Layer와 Activation Function을 통해 변환
FC : 각 frame/segment의 feature를 하나의 anomaly score로 변환
Sigmoid : score를 0~1 범위로 변환

Residual Connection을 사용하여 기존 feature 정보 보존

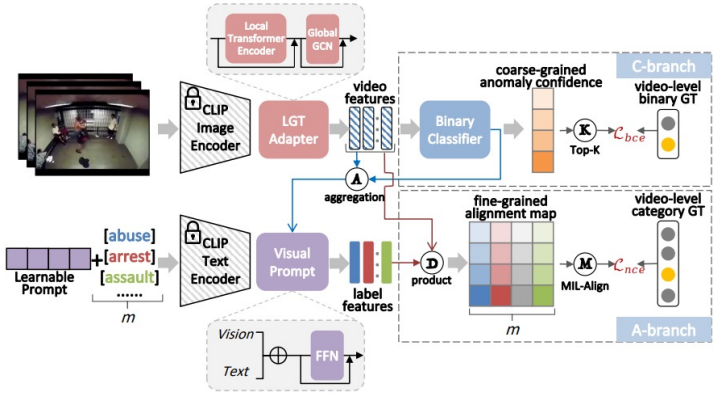
Method

A-Branch(fine-grained alignment branch)

- Learnable prompt와 Text label을 CLIP Text Encoder를 이용해 class embedding으로 변환하고, 이를 각 frame의 visual feature와similarity 비교하여 alignment map M을 생성한다. 이를 통해 Normal/Abnormal 구분을 넘어 이상행동 class까지 세밀하게 구분한다.

$$M \in \mathbb{R}^{n \times m}$$

n : video frame/segment 수
m : text class 수



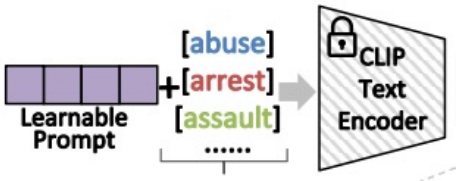
Method

Learnable Prompt

- Fighting, shooting과 같은 짧은 텍스트 라벨만으로는 abnormal event의 의미를 충분히 표현하기 어렵다.
  이를 보완하기 위해 class token에 learnable context token을 결합하여 더 풍부한 semantic information을 포함한 text embedding을 생성

$$t_{init} = Tokenizer(Label)$$

- Text label을 CLIP의 Tokenizer를 통해 class token인 t_{init} 으로 변환



$$t_p = \{c_1, ..., t_{init}, ..., c_l\}$$

- l개의 학습가능한 context token인 $\{c_1, ..., c_l\}$와 t_{init} 을 결합하여 sequence 생성

Method

Anomaly-Focus Visual Prompt

- C-Branch에서 얻은 anomaly confidence를 attention으로 사용하여, abnormal segments의 visual context를 class embedding에 반영한다.

Video-level visual prompt 생성

$$V = Norm\left(A^{\top} X\right)$$

X : Frame별 video feature
A : anomaly confidence

Final instance-specific class embedding 생성

$$T = FFN\left(ADD\left(V, t_{out}\right)\right) + t_{out}$$

ADD : element-wise addition

Residual connection 사용하여 원래 class embedding 정보 보존

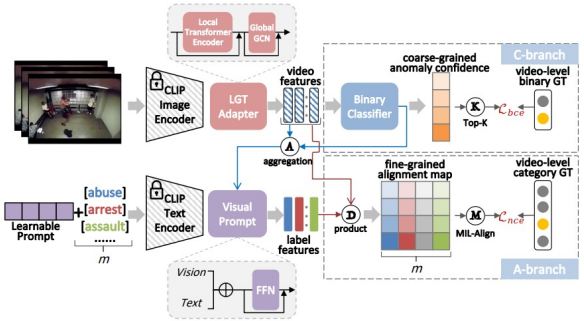


Figure 2: The framework of our proposed VadCLIP.

이후 X와 T를 **이용하여, 모든 class embedding과 frame-level visual feature 사이의 매칭 유사도(match similarities)를 계산하여 alignment map** M을 **생성한다.**

Method

Objective Function

$$\mathcal{L} = \mathcal{L}_{bce} + \mathcal{L}_{nce} + \lambda \mathcal{L}_{cts}$$

- C-Branch : $\mathcal{L}_{bce}$ (Classification Loss)
  Normal과 Abnormal 모두에서 Top-K anomaly confidence 이용하여 Video-level prediction을 만들고, 예측값과 실제 Video label 간의 Binary Cross Entropy를 통해 분류 손실 $\mathcal{L}_{bce}$ 을 계산

- A-Branch : $\mathcal{L}_{nce}$ (Alignment Loss)
  A-Branch의 2가지 문제점
  1. Anomaly confidence가 없다.
  2. Binary가 아닌 Multi-class이다.

  -> 기존 MIL을 그대로 적용하기 어려움

Method

Objective Function

- A-Branch의 2가지 문제점 해결방법
  - MIL-Align : 기존 MIL 개념을 Alignment Map M에 적용하는 방법

M에 있는 각 클래스마다 Top-K를 선택하여 평균을 계산 -> 현재 video와 class의 유사도
위 과정을 모든 class에서 반복하면 $S = \{s_1, s_2, \cdots, s_m\}$ 를 얻는다.

$$p_i = \frac{exp\,(s_i/\tau)}{\sum_j exp\,(s_j/\tau)}$$

$S = \{s_1, s_2, \cdots, s_m\}$ 에 Softmax를 적용하여 각 클래스의 예측 확률 p를 계산한다.
이후 확률p와 정답 label을 Cross Entropy를 통해 alignment Loss $\mathcal{L}_{nce}$를 계산

Method

Objective Function

Contrastive Loss : $\mathcal{L}_{cts}$

- Normal class embedding과 Abnormal class embedding의 cosine similarity를 낮춰 서로 더 잘 구분되도록 Contrastive Loss를 도입한다.

$$\mathcal{L}_{cts} = \sum_{j} max\left(0, \frac{t_n^{\top} t_{aj}}{\|t_n\|_2 \cdot \|t_{aj}\|_2}\right)$$

t_n : Normal class embedding
t_{a_j} : Abnormal class embedding

Loss Function

$$\mathcal{L} = \mathcal{L}_{bce} + \mathcal{L}_{nce} + \lambda \mathcal{L}_{cts}$$